




Machine Learning

Unidad 2: Aprendizaje supervisado



Unidad 2

Aprendizaje supervisado

CLASIFICADORES BAYESIANOS

Sesión 4



Contenido

1. La Incertidumbre y el Pensamiento Probabilístico
2. Programación Tradicional vs. Programación Probabilística
3. Cálculo de la Probabilidad
4. Probabilidades y Machine Learning
5. Teorema de Bayes
6. Clasificación Bayesiana
7. Clasificador o Algoritmo Naive Bayes

1. La Incertidumbre y el Pensamiento Probabilístico

INCERTIDUMBRE, ¿Por qué?



1. La Incertidumbre y el Pensamiento Probabilístico

INCERTIDUMBRE: se refiere a la falta de certeza o seguridad en un resultado o decisión.



DEFINICION

Incetidumbre, es el grado de duda o desconocimiento que existe en relación a una situación o evento.

- La incertidumbre es abordada por la **teoría de la probabilidad**.
- Puede manifestarse en situaciones en las que hay varios resultados posibles o en las que no se tienen suficientes datos o información para predecir con precisión lo que sucederá.

1. La Incertidumbre y el Pensamiento Probabilístico

Hay muchas **causas de la incertidumbre**, pero algunas de las más comunes incluyen:

CAUSAS DE LA INCERTIDUMBRE



Falta de información

Falta de información o conocimiento sobre un evento o resultado futuro.



Complejidad

Los sistemas o procesos son muy complejos o interdependientes.



Cambios en el entorno

El entorno cambiante puede introducir incertidumbre en los resultados futuros.

Por ejemplo, cambios en la economía, la política o el clima pueden afectar la incertidumbre.



Variabilidad

La variabilidad o imprevisibilidad de los resultados.

Por ejemplo, la variabilidad en los mercados financieros puede introducir incertidumbre en los resultados de inversiones.



Factor Humano

Las acciones y decisiones humanas pueden ser una fuente importante de incertidumbre.

Por ejemplo, los errores humanos, las decisiones tomadas con información incompleta o la falta de coordinación entre individuos pueden introducir incertidumbre.

1. La Incertidumbre y el Pensamiento Probabilístico

La incertidumbre es un aspecto común de muchos campos y dominios.

DOMINIOS EN LOS QUE LA INCERTIDUMBRE ES UN FACTOR IMPORTANTE



Finanzas

La incertidumbre en los mercados financieros es un problema importante para inversores y empresas.



Negocios

La incertidumbre es una parte inherente de la toma de decisiones empresariales.



Ingeniería

La incertidumbre es un factor importante en muchos aspectos de la ingeniería, incluyendo la planificación de proyectos, la evaluación de la seguridad y la toma de decisiones de diseño.



Ciencias de la vida

La incertidumbre es un factor importante en muchas áreas de las ciencias de la vida, incluyendo la investigación médica y la evaluación de tratamientos médicos.



Ciencias Sociales


La incertidumbre es un factor importante en muchas áreas de las ciencias sociales, incluyendo la investigación social, la evaluación de políticas públicas y la toma de decisiones políticas.

1. La Incertidumbre y el Pensamiento Probabilístico

Ejemplo de Incertidumbre:

Imagina que estás planeando un viaje y tienes que decidir si llevar un abrigo o no.

- No estás seguro de si hará frío o calor en tu destino.
- Este desconocimiento sobre el clima es una forma de incertidumbre.
- Aunque hay algunas predicciones del tiempo disponibles, no estás seguro de que sean precisas y, por lo tanto, **existe incertidumbre** sobre qué ropa es adecuada para llevar contigo.



2. Programación Tradicional vs. Programación Probabilística

Programación Tradicional

- Se basa en la lógica determinística y en la solución de problemas mediante algoritmos específicos y determinados.
- Supone que los datos y el entorno son conocidos y constantes.
- Se utiliza para tareas que requieren un resultado exacto y predecible.
- Existen muchos lenguajes de programación.
- Se utiliza en aplicaciones como la automatización de procesos, la creación de aplicaciones de escritorio y la resolución de problemas matemáticos complejos.

Programación Probabilística

- Se basa en la **lógica probabilística** y en la **incertidumbre** en la toma de decisiones y en la resolución de problemas.
- Supone que los datos y el entorno son inciertos y pueden variar.
- Se utiliza para tareas que requieren un resultado probable y aproximado.
- Existen muchos lenguajes y librerías especializadas, tales como Pyro de Uber.
- Se utiliza en aplicaciones como la inteligencia artificial, la robótica, el análisis de datos y la toma de decisiones.

2. Programación Tradicional vs. Programación Probabilística

SOLUCION DE PROBLEMAS

Programación Tradicional	Programación Probabilística
Enfocada en la obtención de resultados precisos y determinísticos	Enfocada en la representación y el manejo de la incertidumbre
Utiliza directamente las variables	Utiliza modelos probabilísticos y probabilidades , en vez de utilizar directamente las variables

Ambas técnicas tienen sus ventajas y desventajas, y a menudo se utilizan juntas en diferentes aplicaciones y en diferentes etapas del proceso de solución de problemas.

3. Cálculo de la Probabilidad

LA PROBABILIDAD es la cantidad de veces que sucede un evento dentro de la totalidad de eventos posibles.

La **Probabilidad es independiente** cuando los eventos no están relacionados uno con otro.

Moneda: al lanzarla puede salir cara o sello. Si se vuelve a lanzar puede volver a salir cara o sello, pero el primer evento no influye en los posteriores eventos.

Juegos de azar:

- Lanzar una moneda al aire
- Sacar una carta desde un manojo cartas
- Jugar a la ruleta


Probabilidad independiente

En cambio, la **Probabilidad es dependiente o condicional** cuando un evento necesita de otro para producirse.



3. Cálculo de la Probabilidad


PROBABILIDAD DE EVENTOS INDEPENDIENTES Y DEPENDIENTES (CONDICIONALES)



3. Cálculo de la Probabilidad

LANZAMIENTO DE UNA MONEDA

Cálculo de Probabilidad Independiente




Probabilidad independiente

Pero este tipo de probabilidad no siempre es útil en la vida real...

3. Cálculo de la Probabilidad

LANZAMIENTO DE UNA MONEDA

Cálculo de Probabilidad Dependiente (Condicional)



3. Cálculo de la Probabilidad

Ejercicio de Cálculo de Probabilidades

La persona en la foto se llama Sergio y estas son algunas de sus características:




- Sergio es un músico que le gusta desvelarse.
- Le gusta el rock y el heavy metal.
- Sale de parranda de lunes a sábado.

Pregunta: ¿Qué es más probable?

1. Que Sergio sea un músico.
2. Que Sergio sea un músico y utilice drogas.

POBLACION




Los músicos que consumen drogas son un subconjunto de los músicos
Cuando se dice “y” o “and” significa que el resultado es más pequeño

3. Cálculo de la Probabilidad

USO DE DROGAS

Cálculo de Probabilidad Dependiente (Condicional)



La **probabilidad condicional** la usamos para cuando un evento es dependiente de otro (no son independientes)

¡Estas dos formulas y su notación la utilizaremos posteriormente para comprender el **Teorema de Bayes**!

4. Probabilidades y Machine Learning

PACIENTE	TEST	ENFERMEDAD
1	POSITIVO	PRESENTE
2	NEGATIVO	PRESENTE
3	NEGATIVO	AUSENTE
4	POSITIVO	PRESENTE
5	POSITIVO	PRESENTE
6	POSITIVO	PRESENTE
7	NEGATIVO	AUSENTE
8	NEGATIVO	AUSENTE
9	POSITIVO	PRESENTE
10	POSITIVO	PRESENTE

Probabilidad **a priori** puede ser estimada por la frecuencia:

$P(\text{negativo}) = ?$

$P(\text{positivo}) = ?$

$P(\text{presente}) = ?$

$P(\text{ausente}) = ?$



$P(\text{negativo}) = 4/10$

$P(\text{positivo}) = 6/10$

$P(\text{presente}) = 7/10$

$P(\text{ausente}) = 3/10$

Pero lo que buscamos en Machine Learning es calcular la Probabilidad **a posteriori** o **probabilidad condicional**.

4. Probabilidades y Machine Learning

Probabilidad condicional

$$P(A / B) = \frac{P(A \cap B)}{P(B)}$$

- Cambiamos la Probabilidad **a priori** x **a posteriori**
- Probabilidad de ocurrencia de un evento depende de la ocurrencia de otro $P(A/B)$
- Probabilidad de ocurrencia de un evento A depende de la ocurrencia de un evento B

Ejemplo:

(A) estar enfermo

(B) test dio positivo

Atributos independientes A y B:

Probabilidad de estar enfermo dado que el test dio positivo

$$P(A/B) = P(A)$$

4. Probabilidades y Machine Learning

Probabilidad condicional

$$P(A / B) = \frac{P(A \cap B)}{P(B)}$$

- Es fácil estimar la probabilidad **a priori**
P(B): probabilidad de que el test dé positivo
P(A): probabilidad de que el paciente esté enfermo
P(B/A): probabilidad de que el test dé positivo dado que el paciente realmente esté enfermo
- Es difícil estimar la probabilidad **a posteriori**
P(A/B): probabilidad de que el paciente esté enfermo dado que el test dio positivo.

Teorema de Bayes

5. Teorema de Bayes



Probabilidad Condicional

$$P(A / B) = \frac{P(A \cap B)}{P(B)}$$

Thomas Bayes quiso resolver la siguiente pregunta:

Si lanzo una moneda a una mesa y no se a donde cayó, pero luego, lanzo otra, esta puede caer adelante o atrás, a la izquierda o derecha de la anterior moneda lanzada, entonces:

- ❖ ¿Cómo actualizo mis creencias (hipótesis)?
- ❖ ¿Qué debo hacer para incorporar la evidencia directamente a mi conjunto de creencias (hipótesis) para mejorar continuamente mis probabilidades? -> Aproximarme al resultado.
- Fue en sus últimos años de vida cuando se interesó por el estudio de la Probabilidad.
- Creó el teorema que resolvía esta pregunta, pero lamentablemente falleció sin poderlo publicar o hacer conocido su descubrimiento (lo hizo posteriormente su albacea literario alrededor del año 1663).
- El **Teorema de Bayes** permite calcular la **probabilidad a posteriori**.

5. Teorema de Bayes



- El Teorema de Bayes permite calcular la probabilidad a posteriori.

$$\begin{aligned} P(A \cap B) &= P(A/B)P(B) \\ &= P(B/A)P(A) \end{aligned} \quad \Rightarrow \quad P(A/B) = \frac{P(B/A)P(A)}{P(B)}$$

$P(B)$: ley de probabilidad total

Posteriori: (verosimilitud * *a priori*) / evidencia

Verosimilitud = mide cuán compatible es el modelo o hipótesis (a priori) con los datos observados (evidencia).

En la de inferencia bayesiana, se utiliza junto con la probabilidad previa (a priori o hipótesis) para actualizar nuestras creencias sobre la hipótesis después de observar los datos (evidencia).

Verosimilitud = Alta, si un modelo es muy probable de haber generado la evidencia

Verosimilitud = Baja, si un modelo es muy probable de NO haber generado la evidencia

Probabilidad Condicional

$$P(A/B) = \frac{P(A \cap B)}{P(B)}$$

5. Teorema de Bayes


PROBABILIDAD CONDICIONAL

Ley de la probabilidad total:

- Evento B puede tener 2 resultados posibles:
 - B_1 (B) y B_2 (-B) que pueden formar una partición:
 - $P(A) = P(A \cap B_1) + P(A \cap B_2)$
 - $P(A) = P(A/B_1)P(B_1) + P(A/B_2)P(B_2)$
- Evento B puede tener n posibles resultados mutuamente exclusivos, $B_1, B_2, \dots, B_n$ que formarían, también, una partición.

5. Teorema de Bayes

PROBABILIDAD CONDICIONAL



$$P(\text{Test} \mid \text{Enfermedad}) = 0.75$$

$$P(-\text{Test} \mid -\text{Enfermedad}) = 0.96$$

$$P(\text{Test}) = ?$$


$$P(\text{Test}) = P(\text{Test} \mid \text{Enfermedad})P(\text{Enfermedad}) + P(\text{Test} \mid -\text{Enfermedad})P(-\text{Enfermedad})$$

$$P(\text{Test}) = 0.75 * 0.08 + 0.04 * 0.92$$

$$P(\text{Test}) = 0.098$$

5. Teorema de Bayes

PROBABILIDAD CONDICIONAL



$$P(\text{Test} \mid \text{Enfermedad}) = 0.75$$

$$P(-\text{Test} \mid -\text{Enfermedad}) = 0.96$$

$$P(\text{Test}) = 0.098$$

$$P(\text{Enfermedad} \mid \text{Test}) = ?$$



$$P(\text{Enfermedad} \mid \text{Test}) = \frac{P(\text{Test} \mid \text{Enfermedad})P(\text{Enfermedad})}{P(\text{Test})}$$

$$P(A/B) = \frac{P(B/A)P(A)}{P(B)}$$

$$P(\text{Enfermedad} \mid \text{Test}) = (0.75 \times 0.08) / 0.098 = 0.61$$

6. Clasificación Bayesiana

- Considere ahora que tenemos un evento cuya clase “**y**” tiene un conjunto de posibles estados $i = 1, 2, \dots, m$
- Un nuevo ejemplo pertenece a la clase con probabilidad a posteriori máxima.

$$y_{\text{MAP}} = \arg \max P(y_i/x)$$

$$P(y_i/x) = \frac{P(x/y_i)P(y_i)}{P(x)}$$

Donde:

- $P(x)$ es común a todas las clases
- Considerar las clases equiprobables
- El ejemplo x pertenece a la clase con máxima verosimilitud
- Difícil de calcular los valores

6. Clasificación Bayesiana


❑ Uso de inferencia Bayesiana:

- Cálculo de probabilidades **a posteriori** a partir de la probabilidad **a priori**

❑ Varias alternativas para estimar $P(y_i/x)$

- Producen diferentes funciones discriminantes.
- Clasificador **Naive Bayes**

7. Clasificador o Algoritmo Naive Bayes



- Los **clasificadores Naive Bayes** son algoritmos de aprendizaje automático simples pero potentes. Se denominan Bayes Independientes o Bayes Simples.
- Se basan en la **probabilidad condicional** y el **Teorema de Bayes** con la hipótesis de independencia entre atributos.
- Los conceptos matemáticos detrás del clasificador bayesiano que revisaremos son: la **Probabilidad Condicional** y la **Independencia**.

7. Clasificador o Algoritmo Naive Bayes

¿CÓMO CALCULAR PROBABILIDADES CONDICIONALES?

Caso #1: Dos eventos

- La probabilidad de un evento A dada la ocurrencia de otro evento B

$$P(A|B) = P(A,B)/P(B)$$

Donde

$P(A,B)$ denota la probabilidad de A y B ocurriendo al mismo tiempo

$P(B)$ denota la probabilidad de B (debe ser mayor a cero, entonces, la $P(B)$ debe ser posible)

Caso #2: Múltiples eventos

- Podemos también calcular la probabilidad de un evento A, dada la ocurrencia de múltiples eventos $B_1, B_2, \dots, B^n$:

$$P(A|B_1, B_2, \dots, B^n) = P(A, B_1, B_2, \dots, B^n) / P(B_1, B_2, \dots, B^n)$$

7. Clasificador o Algoritmo Naive Bayes

¿CÓMO CALCULAR PROBABILIDADES CONDICIONALES?

Caso #3: utilizando el Teorema de Bayes

$$P(A|B) = P(B|A)P(A) / P(B)$$

$$P(A|B_1, B_2, \dots, B^n) = P(B_1, B_2, \dots, B^n | A) P(A) / P(B_1, B_2, \dots, B^n)$$

- Observemos que estamos calculando la probabilidad del evento A dado el evento B, invirtiendo el orden de ocurrencia de los eventos del Caso #1 y 2.
- De este teorema se deriva la **regla de la cadena** para calcular la $P(B_1, B_2, \dots, B^n | A)$

$$\begin{aligned} P(B_1, B_2, \dots, B^n, A) &= P(B_1 | B_2, B_3, \dots, B^n, A) P(B_2, B_3, \dots, B^n, A) \\ &= P(B_1 | B_2, B_3, \dots, B^n, A) P(B_2 | B_3, B_4, \dots, B^n, A) P(B_3, B_4, \dots, B^n, A) \\ &= P(B_1 | B_2, B_3, \dots, B^n, A) P(B_2 | B_3, B_4, \dots, B^n, A) \dots P(B_n | A) P(A) \end{aligned}$$

7. Clasificador o Algoritmo Naive Bayes

¿CÓMO CALCULAR PROBABILIDADES CONDICIONALES?

Caso #3: utilizando el Teorema de Bayes

$$P(A|B) = P(B|A)P(A) / P(B)$$

$$P(A|B_1, B_2, \dots, B^n) = P(B_1, B_2, \dots, B^n | A) P(A) / P(B_1, B_2, \dots, B^n)$$

La idea es estimar la probabilidad de cada valor A del atributo meta (valor de clase) dados los valores $B_1, B_2, \dots, B^n$ de los demás atributos

$$P(A|B_1, B_2, \dots, B^n) = \frac{P(A) \cdot \prod_{i=1}^n P(B_i | A)}{\prod_{i=1}^n P(B_i)}$$

7. Clasificador o Algoritmo Naive Bayes

Ejecutar Naive Bayes sobre el siguiente conjunto de datos:

$$P(A|B_1, B_2, \dots, B^n) = \frac{P(A) \cdot \prod_{i=1}^n P(B_i|A)}{\prod_{i=1}^n P(B_i)}$$



Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Outlook (B_1)		
	<i>Yes</i>	<i>No</i>
Sunny	2	3
Overcast	4	0
Rainy	3	2
Sunny	2/9	3/5
Overcast	4/9	0/5
Rainy	3/9	2/5

B_1

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Temperature (B_2)		
	<i>Yes</i>	<i>No</i>
Hot	2	2
Mild	4	2
Cool	3	1
Hot	2/9	2/5
Mild	4/9	2/5
Cool	3/9	1/5



B_1	B_2			
Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Humidity (B_3)		
	<i>Yes</i>	<i>No</i>
High	3	4
Normal	6	1
High	3/9	4/5
Normal	6/9	1/5

B_1	B_2	B_3		
Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Windy (B₄)		
	<i>Yes</i>	<i>No</i>
False	6	2
True	3	3
False	6/9	2/5
True	3/9	3/5

B ₁	B ₂	B ₃	B ₄	
Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Play (A)	
<i>Yes</i>	<i>No</i>
9	5
9/14	5/14

				A
Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

7. Clasificador o Algoritmo Naive Bayes

Outlook (B ₁)			Temperature (B ₂)			Humidity (B ₃)			Windy (B ₄)			Play (A)	
	Yes	No		Yes	No		Yes	No		Yes	No	Yes	No
Sunny	2	3	Hot	2	2	High	3	4	False	6	2	9	5
Overcast	4	0	Mild	4	2	Normal	6	1	True	3	3		
Rainy	3	2	Cool	3	1								
Sunny	2/9	3/5	Hot	2/9	2/5	High	3/9	4/5	False	6/9	2/5	9/14	5/14
Overcast	4/9	0/5	Mild	4/9	2/5	Normal	6/9	1/5	True	3/9	3/5		
Rainy	3/9	2/5	Cool	3/9	1/5								

Outlook	Temp.	Humidity	Windy	Play
Sunny	Cool	High	True	???

$$P(\text{Yes}|\text{Sunny, Cool, High, True}) = (2/9 \times 3/9 \times 3/9 \times 3/9 \times 9/14) / P(\text{Sunny, Cool, High, True})$$

$$P(\text{No}|\text{Sunny, Cool, High, True}) = (3/5 \times 1/5 \times 4/5 \times 3/5 \times 5/14) / P(\text{Sunny, Cool, High, True})$$

$$P(\text{Yes}|\text{Sunny, Cool, High, True}) = \mathbf{0.0053} / P(\text{Sunny, Cool, High, True})$$

$$P(\text{No}|\text{Sunny, Cool, High, True}) = \mathbf{0.0206} / P(\text{Sunny, Cool, High, True})$$

➡ Play = No

7. Clasificador o Algoritmo Naive Bayes

VENTAJAS

- Buen desempeño, inclusive en dominios en el que existe dependencia entre atributos.
- Robusto ante la presencia de ruidos aislados (outliers) y a atributos irrelevantes.
- Probabilidades pueden ser calculadas rápidamente por el conjunto de entrenamiento.
- Proceso de inducción eficiente.
- Fácil de implementar.
- Conocimiento comprensible.

DESVENTAJAS

- No considera relaciones entre los atributos.
- Dificultad de trabajo con atributos continuos.

PREGUNTAS

Dudas y opiniones